

MATRIZ DE CONSISTENCIA DEFINITIVA

Detección experimental de etiquetas Anemia/Normal a partir de imágenes de conjuntiva palpebral

Alcance del estudio. El documento evalúa si un sistema de visión por computadora identifica imágenes etiquetadas como Anemia y si mejora su desempeño frente a configuraciones internas de referencia. La palabra “detección” se limita a la identificación experimental de la etiqueta Anemia en el conjunto evaluado; no equivale a diagnóstico clínico.

1. Matriz rectora de consistencia

Problema / pregunta general	¿El sistema propuesto mejora, frente a configuraciones internas de referencia, la identificación experimental de imágenes de conjuntiva palpebral etiquetadas como Anemia, el desempeño global de clasificación y el tiempo de respuesta end-to-end en el conjunto de evaluación final?
Objetivo general	Alcanzar, mediante el sistema propuesto, una mejora verificable en: (a) la identificación experimental de imágenes etiquetadas como Anemia; (b) el desempeño global de clasificación; y (c) el tiempo de respuesta end-to-end, frente a las configuraciones internas de referencia evaluadas sobre las mismas 285 imágenes.
Hipótesis general de trabajo	El sistema propuesto alcanzará simultáneamente una recuperación de imágenes etiquetadas como Anemia superior a la referencia principal, un desempeño global superior a las configuraciones internas de referencia y un tiempo de respuesta end-to-end no mayor que la referencia principal.
Unidad de análisis	Cada imagen digital de conjuntiva palpebral etiquetada como Anemia o Normal. La evaluación final comprendió 285 imágenes: 141 con etiqueta Anemia y 144 con etiqueta Normal.
Sistema propuesto y referencias internas	Sistema propuesto: flujo con localización automática de región de interés y clasificador de imágenes. Referencia principal: flujo de clasificación con imagen completa. Control analítico: flujo que utiliza una región de interés real durante la evaluación; este control no es desplegable end-to-end.
Variables principales	Variable independiente: configuración completa del sistema de procesamiento de imágenes. Variable dependiente primaria: detección experimental de la etiqueta Anemia. Variables dependientes secundarias: desempeño global, equilibrio entre etiquetas y tiempo de respuesta end-to-end.
Resultado y estado de la hipótesis general	Hipótesis general NO RESPALDADA DE MANERA INTEGRAL. El sistema propuesto mejoró el desempeño global y el equilibrio entre etiquetas, pero no superó a la referencia principal en recuperación de Anemia ni en tiempo de respuesta. En consecuencia, el objetivo general no se alcanzó de manera integral.

Regla de lectura. El “cumplimiento” indica si se alcanzó el criterio de resultado asociado a cada objetivo. Las actividades experimentales fueron ejecutadas; los criterios de desempeño pueden cumplirse o no cumplirse. No se formula un SLA absoluto de tiempo porque el notebook no definió uno antes del test; el tiempo se evalúa comparativamente contra la referencia principal.

2. Problemas específicos, objetivos verificables e hipótesis

Cada objetivo específico expresa un resultado que podía cumplirse o no cumplirse. Los nombres técnicos de las configuraciones se omiten aquí y se consignan solo en la tabla de trazabilidad y resultados.

Problema específico	Objetivo específico orientado a resultado	Hipótesis específica	Criterio verificable de logro	Resultado observado	Estado
PE1. ¿El sistema propuesto recupera más imágenes etiquetadas como Anemia que la referencia principal?	OE1. Alcanzar una recuperación experimental de imágenes etiquetadas como Anemia superior a la referencia principal, expresada mediante recall de Anemia y número de falsos negativos.	El sistema propuesto logrará un recall de Anemia mayor y un número de falsos negativos menor que la referencia principal.	Recall de Anemia > 86.52% y FN < 19.	Sistema propuesto: 80.14% de recall; 113/141 imágenes identificadas; 28 FN. Referencia principal: 86.52%; 122/141; 19 FN.	NO ALCANZADO
PE2. ¿El sistema propuesto obtiene un desempeño global de clasificación superior al de las configuraciones internas de referencia?	OE2. Alcanzar valores de accuracy y F1 macro superiores a los obtenidos por las configuraciones internas de referencia.	El sistema propuesto logrará accuracy y F1 macro mayores que ambas configuraciones internas de referencia.	Accuracy > 72.28% y F1 macro > 71.78% y > 70.90%.	Sistema propuesto: accuracy=81.40%; F1 macro=81.40%. Referencias: 72.28%/71.78% y 72.28%/70.90%.	ALCANZADO DESCRIPTIVAMENTE
PE3. ¿El sistema propuesto clasifica las etiquetas con mayor equilibrio que las configuraciones internas de referencia?	OE3. Alcanzar una diferencia absoluta entre el recall de Anemia y el recall de Normal menor que la de las configuraciones internas de referencia.	El sistema propuesto logrará el menor desequilibrio entre la recuperación de las etiquetas Anemia y Normal.	$\Delta \text{ recall} = \text{recall Anemia} - \text{recall Normal} < 28.19 \text{ pp y } < 42.00 \text{ pp}.$	Sistema propuesto: $\Delta \text{ recall}=2.50 \text{ pp}.$ Referencias: 28.19 pp y 42.00 pp.	ALCANZADO BAJO ESTE INDICADOR
PE4. ¿El sistema propuesto ofrece una respuesta end-to-end no mayor que la referencia principal y completa la evaluación sin fallos de localización?	OE4. Alcanzar un tiempo de respuesta end-to-end no mayor que la referencia principal y procesar sin fallos de localización las 285 imágenes de evaluación final.	El sistema propuesto procesará las 285 imágenes sin fallos de localización y con un tiempo por imagen no mayor que la referencia principal.	285/285 imágenes; fallos de localización=0; tiempo $\leq 23.47 \text{ ms/imagen}.$	Sistema propuesto: 285/285 imágenes; 0 fallos de localización; 51.68 ms/imagen. Referencia principal: 23.47 ms/imagen.	NO ALCANZADO INTEGRALMENTE

Resultado global de los objetivos. No se alcanzaron todos. OE1 no se alcanzó porque la recuperación de la etiqueta Anemia y el número de falsos negativos fueron menos favorables que la referencia principal. OE4 tampoco se alcanzó de manera integral por mayor tiempo de respuesta, aunque la continuidad del procesamiento sí se cumplió. OE2 y OE3 se alcanzaron bajo sus criterios comparativos.

3. Variables, indicadores y criterios de interpretación

Componente	Definición operacional	Indicadores	Regla de interpretación
Variable independiente: configuración completa del sistema	La configuración integra la forma de entrada de imagen o región de interés, el clasificador y la calibración aplicada solamente con validación.	Tipo de entrada o región de interés; modelo clasificador; temperatura calibrada; umbral de decisión.	La comparación es entre sistemas completos calibrados. No permite atribuir el resultado exclusivamente a un solo componente técnico.
Variable dependiente primaria: detección experimental de la etiqueta Anemia	Capacidad de identificar como Anemia las imágenes del conjunto final cuya etiqueta verdadera es Anemia.	Recall de Anemia = TP/(TP+FN); verdaderos positivos; falsos negativos.	Esta es la variable central porque responde a si el sistema identifica o no identifica la etiqueta Anemia. No equivale a sensibilidad clínica ni a diagnóstico médico.
Variable dependiente secundaria: desempeño global	Comportamiento global al clasificar etiquetas Anemia/Normal.	Accuracy; F1 macro; precisión y recall por clase; matriz de confusión.	Un mayor desempeño global no demuestra por sí mismo una mayor recuperación de Anemia.
Variable dependiente secundaria: equilibrio y respuesta operativa	Balance entre la recuperación de las etiquetas y continuidad/tiempo del procesamiento.	Δ recall; AUC-ROC; AP; tasa de detección; fallos de localización; ms/imagen.	El equilibrio se define exclusivamente como Δ recall. AUC-ROC y AP son evidencia complementaria; el tiempo se interpreta frente a la referencia principal porque no existe SLA previo documentado.

4. Evidencia complementaria del sistema propuesto

Elemento	Resultado verificable	Interpretación permitida
Matriz de confusión	113 verdaderos positivos; 28 falsos negativos; 25 falsos positivos; 119 verdaderos negativos.	El sistema identificó experimentalmente 113 de 141 imágenes con etiqueta Anemia. Esta cifra es inferior a las 122 identificadas por la referencia principal.
Capacidad discriminativa	AUC-ROC=0.873; AP=0.840. En el umbral 0.55: recall Anemia=0.801; FPR=0.174.	Las probabilidades separaron las etiquetas del conjunto final por encima del azar. No acreditan utilidad clínica fuera de la muestra evaluada.
Continuidad del procesamiento	Tasa de detección=1.00; fallos de localización=0; 285/285 imágenes procesadas.	El flujo end-to-end se ejecutó de manera continua en el conjunto final. Esto no compensa el mayor tiempo frente a la referencia principal.

Nota sobre el tiempo. No se declara “tiempo real” ni cumplimiento de SLA, porque el notebook no establece un umbral absoluto previo a la evaluación. El resultado temporal se compara estrictamente con la referencia principal: 51.68 ms/imagen frente a 23.47 ms/imagen.

5. Trazabilidad del flujo de datos y decisiones

La secuencia se limita a las entradas, controles y salidas presentes en cp_v3_semana6_pipeline(29).ipynb. Los nombres técnicos se incluyen solo para sostener la trazabilidad del experimento.

Etapa		Control ejecutado	Salida verificable	Lectura permitida / límite
1. Entorno y datos		Validación de entorno, CUDA, rutas y carga de data_clean.yaml. Clases reportadas: 0=Anemia; 1=Normal.	Python 3.10.0; CUDA 12.6; GPU GTX 1660 SUPER. Particiones: entrenamiento=2,053; validación=251; test=285.	La evidencia confirma ejecución técnica y disponibilidad de las particiones. No acredita el estándar clínico de las etiquetas.
2. Control de solapamiento		Comparación entrenamiento-validación, entrenamiento-test y validación-test con fail_on_leakage=True.	0 coincidencias por identificador de imagen base en los tres pares.	Controla solapamiento por archivo o aumento. No verifica independencia por paciente.
3. Configuraciones comparadas		Sistema propuesto: ROI automática por YOLOv8n + EfficientNet-B0. Referencia principal: imagen completa + EfficientNet-B0. Control analítico: ROI con bbox real + EfficientNet-B0.	Tres sistemas evaluados sobre las mismas 285 imágenes del test.	El control analítico utiliza bbox real, por lo que no representa un flujo desplegable end-to-end.
4. Calibración		Temperature scaling y selección de umbral por F1 macro, exclusivamente con validación.	Umbral final: referencia principal=0.41; control analítico=0.73; sistema propuesto=0.55.	El test no se utilizó para fijar temperatura ni umbrales. Se comparan sistemas calibrados con parámetros diferentes.
5. Evaluación final		Cálculo de métricas, matriz de confusión, curvas ROC/Precision-Recall y tiempos de procesamiento.	Sistema propuesto: 232 aciertos, 53 errores, matriz [[113,28],[25,119]].	No se ejecutaron pruebas inferenciales de significancia, intervalos de confianza ni comparación externa con literatura.
6. Revisión de ejecución		Revisión de los 11 pasos registrados en la ejecución principal y del bloque de figuras.	Pasos 1/11 a 11/11 en estado OK. Figuras finales sin advertencias críticas reportadas.	La ejecución fue consistente; ello no convierte los resultados en validación clínica.

6. Resultados consolidados de la evaluación final

Rol en el estudio	Flujo técnico	Accuracy	F1 macro	Recall Anemia	FN	Tiempo (ms/imagen)
Referencia principal	Imagen completa + EfficientNet-B0	72.28%	71.78%	86.52%	19	23.47
Control analítico	ROI con bbox real + EfficientNet-B0	72.28%	70.90%	51.06%	69	16.78
Sistema propuesto	ROI automática por YOLOv8n + EfficientNet-B0	81.40%	81.40%	80.14%	28	51.68

Lectura central. El sistema propuesto fue superior en desempeño global, pero no fue superior en recuperación de la etiqueta Anemia ni en tiempo de respuesta frente a la referencia principal.

7. Dictamen final de logro y límites de interpretación

Aspecto evaluado	Conclusión verificable	Estado
Recuperación experimental de la etiqueta Anemia	El sistema propuesto identificó 113/141 imágenes etiquetadas como Anemia (80.14%) y tuvo 28 FN. La referencia principal identificó 122/141 (86.52%) y tuvo 19 FN.	NO ALCANZADO frente a la referencia principal
Desempeño global	El sistema propuesto obtuvo accuracy=81.40% y F1 macro=81.40%, valores superiores a las configuraciones internas de referencia.	ALCANZADO DESCRIPTIVAMENTE
Equilibrio entre etiquetas	El sistema propuesto obtuvo Δ recall=2.50 pp, menor que 28.19 pp y 42.00 pp de las referencias.	ALCANZADO bajo este indicador
Tiempo y continuidad end-to-end	El sistema propuesto procesó 285/285 imágenes sin fallos de localización, pero tardó 51.68 ms/imagen frente a 23.47 ms/imagen de la referencia principal.	NO ALCANZADO INTEGRALMENTE
Inferencia clínica y generalización	No se ejecutaron validación clínica, estándar de referencia documentado, comparación con estado del arte, análisis de significancia, auditoría por paciente ni validación anatómica de ROI.	NO DEMOSTRADO / NO EVALUADO

8. Expresiones que deben y no deben usarse en la tesis

No usar	Redacción defendible
“El sistema detecta mejor la anemia.”	“El sistema propuesto identificó experimentalmente 113 de 141 imágenes etiquetadas como Anemia, pero no superó a la referencia principal en recuperación de esa etiqueta.”
“El sistema diagnostica anemia.”	“El sistema clasifica experimentalmente etiquetas Anemia/Normal en imágenes de conjuntiva palpebral del conjunto evaluado.”
“El sistema es más rápido.”	“El sistema procesó el conjunto final sin fallos de localización, pero tardó más por imagen que la referencia principal.”
“El sistema es estadísticamente superior.”	“La diferencia observada en desempeño global es descriptiva; no se ejecutaron pruebas inferenciales de significancia.”
“No existe leakage.”	“No se detectó solapamiento por identificador de imagen base; la independencia por paciente no fue verificada.”

Veredicto de presentación. La matriz es presentable como tesis experimental comparativa de visión por computadora. La conclusión obligatoria es: el sistema propuesto mejoró el desempeño global y el equilibrio relativo entre etiquetas, pero no mejoró la recuperación de imágenes etiquetadas como Anemia ni el tiempo de respuesta frente a la referencia principal. No debe presentarse como diagnóstico clínico, demostración de mayor sensibilidad para anemia, superioridad estadística o cumplimiento de un SLA no definido.