

MATRIZ DE CONSISTENCIA

Detección experimental de etiquetas Anemia/Normal a partir de imágenes de conjuntiva palpebral

Alcance científico. El estudio evalúa el comportamiento experimental de un sistema de visión por computadora sobre imágenes etiquetadas como Anemia o Normal. “Detección” significa identificar la etiqueta Anemia en el conjunto evaluado; no equivale a diagnóstico clínico de anemia.

1. Matriz rectora: problema, objetivo, hipótesis y dictamen de logro

Problema / pregunta general	¿El sistema propuesto, compuesto por localización automática de una región de interés (ROI) mediante YOLOv8n y clasificación con EfficientNet-B0, mejora la detección experimental de imágenes de conjuntiva palpebral etiquetadas como Anemia, medida mediante recall de Anemia y falsos negativos, y simultáneamente mejora el desempeño global frente a configuraciones internas de referencia?
Objetivo general evaluable	Determinar si el sistema propuesto mejora simultáneamente: (a) la detección experimental de imágenes etiquetadas como Anemia, mediante mayor o igual recall de Anemia y menor o igual número de falsos negativos; y (b) el desempeño global de clasificación, mediante mayor accuracy y F1 macro, frente a las configuraciones internas de referencia en las mismas 285 imágenes de evaluación final.
Hipótesis general de trabajo	El sistema propuesto alcanzará recall de Anemia mayor o igual al de la referencia principal, menor o igual número de falsos negativos y valores superiores de accuracy y F1 macro frente a las configuraciones internas de referencia.
Unidad de análisis	Cada imagen digital de conjuntiva palpebral etiquetada como Anemia o Normal. La evaluación final incluyó 285 imágenes: 141 con etiqueta Anemia y 144 con etiqueta Normal.
Sistema propuesto y referencias internas	Sistema propuesto: Var2 = ROI automática por YOLOv8n + EfficientNet-B0. Referencia principal: Baseline = imagen completa + EfficientNet-B0. Referencia analítica: Var1 = ROI con bbox real + EfficientNet-B0; no representa un flujo desplegable end-to-end.
Criterio de logro integral	Se considera logrado integralmente solo si Var2 cumple simultáneamente: recall de Anemia $\geq$ 86.52%, falsos negativos $\leq$ 19, y accuracy y F1 macro estrictamente mayores que Baseline y Var1.
Resultado observado y dictamen	Var2 alcanzó recall de Anemia=80.14% y 28 falsos negativos; por ello no superó a Baseline en detección de la etiqueta Anemia. Sí obtuvo mayor accuracy=81.40% y F1 macro=81.40%. Dictamen: OBJETIVO GENERAL NO LOGRADO DE MANERA INTEGRAL; logro parcial en desempeño global, no en recuperación de Anemia.

Lectura imprescindible. El sistema sí identifica experimentalmente 113 de 141 imágenes etiquetadas como Anemia (80.14%). Sin embargo, Baseline identificó 122 de 141 (86.52%). Por tanto, Var2 no puede presentarse como una mejora de la detección de Anemia frente a Baseline en el punto de operación evaluado.

2. Objetivos específicos: criterio de logro, resultado y estado

Objetivo específico orientado a resultado	Criterio de logro o no logro	Resultado verificable del notebook	Dictamen objetivo
OE1. Determinar si el sistema propuesto mejora la detección experimental de imágenes etiquetadas como Anemia frente a la referencia principal.	Logro: recall de Anemia >= 86.52% y falsos negativos <= 19. No logro: no cumplir cualquiera de ambos criterios.	Var2: recall Anemia=80.14%; 113/141 imágenes identificadas; 28 FN. Baseline: recall Anemia=86.52%; 122/141; 19 FN.	NO LOGRADO. Var2 identifica imágenes etiquetadas como Anemia, pero no las recupera mejor que Baseline en el umbral calibrado.
OE2. Determinar si el sistema propuesto mejora el desempeño global de clasificación frente a las configuraciones internas de referencia.	Logro: accuracy y F1 macro de Var2 estrictamente mayores que Baseline y Var1.	Var2: accuracy=81.40%; F1 macro=81.40%. Baseline: 72.28%; 71.78%. Var1: 72.28%; 70.90%.	LOGRADO DESCRIPTIVAMENTE. Var2 obtuvo el mayor desempeño global. No se demostró significancia estadística.
OE3. Determinar si el sistema propuesto logra un desempeño más equilibrado entre las etiquetas Anemia y Normal.	Logro: diferencia absoluta entre recall de Anemia y recall de Normal menor que ambas referencias.	Delta recall: Var2=2.50 pp; Baseline=28.19 pp; Var1=42.00 pp. Var2: 25 FP y 28 FN.	LOGRADO CON ESTE INDICADOR. El equilibrio no compensa el menor recall de Anemia frente a Baseline.
OE4. Determinar si la salida probabilística del sistema propuesto separa las etiquetas Anemia y Normal por encima del azar en la evaluación final.	Logro: AUC-ROC > 0.50. AP se reporta como indicador complementario.	AUC-ROC=0.873; AP=0.840. Con umbral 0.55: recall Anemia=0.801; FPR=0.174.	LOGRADO EN ESTA MUESTRA. Demuestra separación probabilística sobre las etiquetas evaluadas, no utilidad clínica externa.
OE5. Determinar si el sistema propuesto completa la evaluación end-to-end sin fallos de generación de ROI y cuantificar su costo temporal.	Logro operativo: 285/285 imágenes procesadas y detection_failures=0. La latencia se describe; no se clasificó como tiempo real por no existir umbral predefinido.	Var2: 285/285; detection_rate=1.00; detection_failures=0; 51.68 ms/imagen. Baseline=23.47 ms/imagen; Var1=16.78 ms/imagen.	LOGRADO OPERATIVAMENTE. El flujo completó el test, pero fue 2.20 veces más lento que Baseline.

Resultado global de los objetivos. No se cumplieron todos. OE1, que es el objetivo principal de detección de la etiqueta Anemia, NO se cumplió frente a Baseline. OE2, OE3, OE4 y OE5 se cumplieron dentro de sus criterios y límites declarados.

3. Variables, operacionalización y coherencia metodológica

Variable / dimensión	Definición operacional y categorías	Indicadores	Regla de interpretación
VI: configuración completa del pipeline	Sistema propuesto: Var2 (ROI automática por YOLOv8n + EfficientNet-B0). Referencia principal: Baseline (imagen completa + EfficientNet-B0). Referencia analítica: Var1 (ROI con bbox real + EfficientNet-B0). Cada flujo fue calibrado únicamente con validación.	Origen de la imagen/ROI; clasificador; temperatura calibrada; umbral de decisión. Umbrales: Baseline=0.41; Var1=0.73; Var2=0.55.	La comparación es entre pipelines completos calibrados. No aísla el efecto exclusivo de la ROI. Var1 es control analítico y no flujo desplegable.
VD primaria: detección experimental de la etiqueta Anemia	Capacidad del sistema para identificar como Anemia las imágenes del conjunto final que tienen etiqueta Anemia.	Recall de Anemia = TP/(TP+FN); verdaderos positivos; falsos negativos.	Es la dimensión principal porque responde a “detecta o no detecta” la etiqueta Anemia. No equivale a sensibilidad clínica ni diagnóstico médico.
VD secundaria: desempeño global de clasificación	Comportamiento global del pipeline al clasificar etiquetas Anemia/Normal.	Accuracy; F1 macro; precisión y recall por clase; matriz de confusión.	Complementa la detección primaria. Un mayor accuracy no demuestra, por sí solo, mayor recuperación de Anemia.
VD secundaria: equilibrio, discriminación y operación	Balance entre recalls de ambas etiquetas; capacidad probabilística de separación; continuidad y tiempo de procesamiento.	Delta recall; AUC-ROC; AP; FPR; detection_rate; detection_failures; ms/imagen.	El equilibrio se define solo como recall Anemia - recall Normal . AUC/AP y operación describen el conjunto evaluado.

4. Trazabilidad del flujo de datos y decisiones

Etapas / evidencia revisada	Control ejecutado	Salida verificable y lectura permitida
1. Entorno y configuración Celda 32, pasos 1-3	Se validaron entorno .venv, CUDA, rutas y carga de data_clean.yaml. Clases reportadas: 0=Anemia; 1=Normal.	Estado OK. Python 3.10.0, CUDA 12.6, GTX 1660 SUPER. Particiones cargadas: train=2,053; validación=251; test=285.
2. Auditoría de contaminación Celda 32, paso 4	Comparación train-validación, train-test y validación-test con fail_on_leakage=True.	0 coincidencias por identificador base en los tres pares. Controla solapamiento por archivo/aumento; no verifica independencia por paciente.
3. Construcción de las tres configuraciones Celda 32, pasos 6-9	YOLOv8n para ROI automática; Baseline con imagen completa; Var1 con bbox real; Var2 con ROI automática.	Los tres flujos se evaluaron sobre las mismas 285 imágenes. La ROI no cuenta con validación anatómica por expertos.
4. Calibración Celda 32, pasos 7-9	Temperature scaling y selección de umbral para F1 macro solo con validación.	El test no se usó para definir temperaturas ni umbrales. Se comparan pipelines calibrados con umbrales diferentes.
5. Evaluación final y figuras Celdas 33-34	Métricas, matriz de confusión, curvas ROC/Precision-Recall, tiempos y figuras de defensa.	Var2: 232 aciertos, 53 errores; matriz [[113,28],[25,119]]. Figuras finales sin advertencias críticas reportadas.
6. Revisión de ejecución Celda 32	Se verificaron los 11 pasos registrados del pipeline.	Los pasos 1/11 a 11/11 registraron estado OK. No se identificaron salidas de error en las celdas de ejecución revisadas.

5. Resultados consolidados de la evaluación final

Cómo leer esta tabla. La columna “recall Anemia” es la medida central de detección experimental de la etiqueta Anemia. Var2 tiene el mayor desempeño global, pero Baseline tiene mayor recall de Anemia y menos falsos negativos.

Configuración	Entrada / flujo	Accuracy	F1 macro	Recall Anemia	Recall Normal	Delta recall	FP	FN	Tiempo (ms/img)
Baseline	Imagen completa + EfficientNet-B0	72.28%	71.78%	86.52%	58.33%	28.19 pp	60	19	23.47
Var1	ROI con bbox real + EfficientNet-B0	72.28%	70.90%	51.06%	93.06%	42.00 pp	10	69	16.78
Var2 Sistema propuesto	ROI automática YOLOv8n + EfficientNet-B0	81.40%	81.40%	80.14%	82.64%	2.50 pp	25	28	51.68

6. Dictamen de cumplimiento y límites de interpretación

Aspecto	Conclusión verificable	Estado
Detección de la etiqueta Anemia	Var2 detectó 113/141 imágenes etiquetadas como Anemia (80.14%), pero Baseline detectó 122/141 (86.52%) y cometió menos FN (19 frente a 28).	NO LOGRADO frente a Baseline
Desempeño global	Var2 obtuvo accuracy=81.40% y F1 macro=81.40%, valores mayores que Baseline y Var1.	LOGRADO descriptivamente
Equilibrio entre etiquetas	Var2 obtuvo el menor Delta recall: 2.50 pp frente a 28.19 pp y 42.00 pp.	LOGRADO bajo este indicador
Discriminación probabilística	AUC-ROC=0.873 y AP=0.840 en el conjunto final.	LOGRADO en esta muestra
Operación end-to-end	Var2 procesó 285/285 sin fallos de ROI; latencia=51.68 ms/imagen.	LOGRADO operativamente
Inferencia clínica y generalización	No se ejecutaron validación clínica, comparación con estado del arte, significancia estadística, auditoría por paciente ni validación anatómica de ROI.	NO DEMOSTRADO / NO EVALUADO

Decisión de presentación. La matriz es presentable como tesis experimental comparativa de visión por computadora si se afirma: “Var2 mejoró el desempeño global y el equilibrio relativo entre etiquetas, pero no mejoró la recuperación de imágenes etiquetadas como Anemia frente a Baseline.” No debe afirmarse diagnóstico clínico, superioridad estadística, validación médica ni mayor sensibilidad para Anemia.

7. Revisión documental por archivo y resultado

Archivo o elemento	Trazas revisadas	Resultado de revisión
cp_v3_semana6_pipeline(28).ipynb	36 celdas. C32: 11 pasos y métricas; C33: test formal; C34: figuras; C35: demo excluida.	COHERENTE. Métricas y límites coinciden con las salidas auditadas.
data_clean.yaml (referido por el notebook)	No fue adjuntado. C32, paso 3, reporta carga exitosa, particiones y clases.	VERIFICACIÓN INDIRECTA. Sin afirmaciones fuera de lo reportado por el notebook.
Documento previo orientado a logro	Se corrigió la jerarquía: detección de Anemia es la dimensión primaria y el no logro queda explícito.	SUSTITUIDO por esta versión corregida.